

16 ejemplos reales de sesgo en IA

01

Ejemplo 1: Sesgo sistémico contra mujeres mayores cuando la IA escribe hojas de vida

EMPLEO | EDAD | GÉNERO

Un estudio importante publicado en Nature y reportado por la Universidad de Stanford en octubre de 2025 encontró que los grandes modelos de lenguaje, como ChatGPT, pueden contener sesgos profundos contra las mujeres mayores en el lugar de trabajo.

Cuando los investigadores pidieron a la IA generar hojas de vida para candidatas hipotéticas, el sistema las describió de forma consistente como más jóvenes y menos experimentadas que sus contrapartes masculinas.

Cuando al mismo sistema se le pidió calificar esas hojas de vida, otorgó puntuaciones más altas a hombres mayores que a mujeres mayores, incluso cuando las cualificaciones eran idénticas. Esto sugiere que las herramientas de IA usadas en reclutamiento podrían perjudicar de manera sistemática a mujeres mayores que buscan empleo.

02

Ejemplo 2: Sesgo de IA en el diagnóstico de cáncer de piel para tonos de piel diversos

SALUD | DERMATOLOGÍA | REPRESENTACIÓN DE DATOS

Un estudio de investigación publicado el 22 de abril de 2025 en la revista Dermis resaltó disparidades significativas en la forma en que la inteligencia artificial identifica lesiones malignas en distintos grupos demográficos.

La mayoría de los modelos de IA se entrenan con conjuntos de datos donde predominan pacientes de piel clara. Por ejemplo, una revisión de 21 conjuntos de datos globales con más de 100.000 imágenes encontró que solo 11 imágenes representaban explícitamente tonos de piel marrón o negra, y ninguna correspondía a personas de origen africano o del sur de Asia.

Al probarse en conjuntos de datos más diversos, los modelos líderes mostraron caídas importantes de precisión para pieles más oscuras, especialmente en los tipos Fitzpatrick IV a VI. El texto original indica que estos modelos son más propensos a clasificar erróneamente lesiones cancerosas como benignas en personas de piel oscura, lo que podría retrasar tratamientos vitales.

Estos puntos ciegos muestran la necesidad crítica de desarrollar IA inclusiva. Sin datos diversos que contemplen tonos de piel y presentaciones clínicas diferentes, las herramientas de IA corren el riesgo de profundizar inequidades en salud y brindar atención subóptima a grupos étnicos subrepresentados.

03

Ejemplo 3: Un estudio revela sesgo de género en sistemas de IA para decisiones de asistencia social

SERVICIOS PÚBLICOS | GÉNERO | ASIGNACIÓN DE CUIDADOS

Un informe en BMC Medical Informatics and Decision Making, del 11 de agosto de 2025, menciona que investigadores de LSE probaron resúmenes generados por IA a partir de 617 notas reales de casos de asistencia social y encontraron sesgos relacionados con el género.

Los investigadores modificaron solo el género y procesaron esas notas con varios LLM, produciendo 29.616 pares de comparación. Según el documento, la herramienta Gemma de Google describió los problemas de salud de hombres con términos como "discapacitado", "incapaz" y "complejo" con mucha más frecuencia que los de mujeres, quienes fueron presentadas como más independientes a pesar de tener necesidades similares.

El investigador principal, Dr. Sam Rickman, advirtió que este sesgo podría hacer que los consejos o gobiernos locales asignaran menos cuidados a mujeres. También pidió salvaguardas urgentes: transparencia, pruebas rigurosas de sesgo y supervisión legal de los sistemas de IA usados en servicios públicos.

04

Ejemplo 4: La IA penaliza peinados naturales de mujeres negras como menos profesionales

IMAGEN | CULTURA | EMPLEO

Una prueba reciente publicada el 10 de agosto de 2025 con herramientas principales de IA reveló que, al evaluar imágenes, las trenzas y los peinados naturales de mujeres negras tenían mayor probabilidad de recibir puntuaciones más bajas de "inteligencia" y "profesionalismo"; sesgos que rara vez aparecían con el cabello de mujeres blancas.

Estos hallazgos sugieren que evaluaciones aparentemente neutrales pueden codificar y perpetuar estereotipos culturales dañinos, penalizando injustamente a mujeres negras en contextos sociales y laborales.

El estudio subraya la urgencia de auditorías robustas de sesgo, reformas de diseño y responsabilidad en sistemas de IA, especialmente aquellos utilizados en contratación y entornos profesionales.

05

Ejemplo 5: Demanda contra Workday por sesgo de IA en contratación: edad, raza y discapacidad

EMPLEO | LITIGIO | DISCRIMINACIÓN

Derek Mobley, una persona negra que buscaba empleo, mayor de 40 años y con discapacidad, presento una demanda en febrero de 2023 alegando que el sistema de filtrado de candidatos basado en IA de Workday lo discriminó a él, y potencialmente a cientos de miles de personas, por edad, raza y discapacidad.

El 16 de mayo de 2025, la jueza Rita Lin negó la moción de Workday para desestimar el caso y concedió certificación preliminar de acción colectiva para la reclamación por discriminación por edad bajo la ADEA. Esto permitió que el caso continuara en nombre de solicitantes de 40 años o más que no recibieron recomendaciones desde septiembre de 2020.

El caso entro en fase de descubrimiento, con tribunales exigiendo a Workday entregar datos como listas de empleadores y detalles técnicos de sus procesos de filtrado por IA. Esa información podría influir en la manera en que futuros litigios y regulaciones aborden el sesgo algorítmico en contratación.

Workday rechaza las acusaciones, señala que la orden del tribunal es procedimental y se basa en alegaciones, no en evidencia, y sostiene que la demanda carece de mérito.

Analistas legales advierten que este caso podría convertirse en un referente para litigios sobre sesgo de IA en contratación, a medida que empleadores y proveedores de tecnología de recursos humanos enfrentan mayor escrutinio.

06

Ejemplo 6: Sesgo racial en planes de tratamiento psiquiátrico generados por IA

SALUD MENTAL | RAZA | DECISIÓN CLÍNICA

Un estudio liderado por Cedars-Sinai y publicado el 20 de junio de 2025 encontró que grandes modelos de lenguaje líderes, incluidos Claude, ChatGPT, Gemini y NewMes-15, tienden a generar recomendaciones de tratamiento menos efectivas cuando la raza del paciente, ya sea sugerida o explícitamente indicada, es afroamericana.

Aunque las decisiones diagnósticas mostraron poca evidencia de sesgo racial, los regímenes de tratamiento revelaron disparidades claras. Según el documento, NewMes-15 mostro el sesgo más pronunciado y Gemini el menor.

Estos resultados generan preocupaciones significativas sobre el uso de IA en atención psiquiátrica y subrayan la necesidad urgente de evaluación rigurosa de sesgos y supervisión en herramientas de apoyo a

decisiones médicas.

07

Ejemplo 7: Como la IA reforzó la desigualdad racial en el sistema de justicia

JUSTICIA PENAL | RAZA | RIESGO DE REINCIDENCIA

El algoritmo COMPAS, desarrollado por Northpointe, hoy Equivant, se utiliza para predecir el riesgo de reincidencia en tribunales de Estados Unidos. Un análisis de ProPublica de 2016 encontró que los acusados negros tenían casi el doble de probabilidad de ser clasificados erróneamente como de alto riesgo: 45% frente a 23% en acusados blancos.

A la inversa, los acusados blancos tenían mayor probabilidad de ser etiquetados erróneamente como de bajo riesgo, incluso cuando reincidían.

Estos hallazgos expusieron sesgo racial significativo en el algoritmo y generaron preocupaciones sobre la equidad y transparencia de las herramientas de IA utilizadas en el sistema de justicia penal.

08

Ejemplo 8: La IA de Apple para tarjetas de crédito con sesgo de género

FINANZAS | CRÉDITO | GÉNERO

El algoritmo de la tarjeta de crédito de Apple, administrado por Goldman Sachs, enfrentó escrutinio después de que supuestamente ofreciera límites de crédito considerablemente más bajos a mujeres que a sus esposos, incluso cuando ellas tenían mejores puntajes crediticios e ingresos más altos.

El emprendedor tecnológico David Heinemeier Hansson señaló que recibió un límite de crédito 20 veces mayor que el de su esposa, a pesar de que ella tenía un puntaje crediticio superior y cuentas financieras compartidas.

De forma similar, el cofundador de Apple Steve Wozniak informó que recibió un límite diez veces mayor que el de su esposa, aunque ambos tenían activos y cuentas conjuntas.

09

Ejemplo 9: La IA generativa sexualiza a las mujeres y estereotipa profesiones

IA GENERATIVA | IMAGEN | ESTEREOTIPOS

Herramientas populares de generación de imágenes como DALL·E 2 y Stable Diffusion mostraron sesgos significativos. Cuando se les pedía generar imágenes de profesiones como "CEO" o "ingeniero", producían de manera abrumadora imágenes de hombres blancos. En cambio, indicaciones como "persona de limpieza" o "enfermera" generaban principalmente imágenes de mujeres o minorías, reflejando estereotipos incrustados en los datos de entrenamiento.

A finales de 2022, la aplicación viral Lensa AI generó avatares estilizados a partir de selfies de usuarios. Varias personas reportaron sesgos de género: los avatares femeninos aparecían con frecuencia sexualizados o en poses sugerentes, sin importar la imagen original. Los avatares masculinos, por su parte, eran representados con más frecuencia como heroicos o poderosos, mostrando representaciones estereotipadas de género.

10

Ejemplo 10: El algoritmo de LinkedIn con sesgo de IA en búsquedas de empleo

EMPLEO | RECOMENDACIONES | GÉNERO

Los sistemas de recomendación de empleo de LinkedIn, impulsados por IA, enfrentaron acusaciones de perpetuar sesgos de género. Un estudio de 2022 introdujo una métrica de equidad para detectar sesgo algorítmico y reveló que los algoritmos de LinkedIn favorecían a candidatos hombres frente a candidatas mujeres igualmente calificadas, generando recomendaciones laborales desiguales.

Adicionalmente, una investigación de 2016 encontró que el algoritmo de búsqueda de LinkedIn sugería alternativas masculinas cuando los usuarios buscaban nombres femeninos comunes; por ejemplo, sugería

"Stephen Williams" al buscar "Stephanie Williams".

Estos casos resaltan los desafíos de asegurar que los sistemas de IA no refuercen sesgos sociales existentes. Según el texto original, el equipo de LinkedIn construyó un nuevo algoritmo de IA para enfrentar este problema.

11 Ejemplo 11: Sesgo de IA relacionado con la edad en Facebook

PUBLICIDAD | EMPLEO | EDAD

ProPublica reveló un sesgo significativo por edad en la publicidad laboral segmentada de Facebook. Los empleadores podían excluir a trabajadores mayores de ver ofertas de empleo al restringir la visibilidad de anuncios a grupos más jóvenes, principalmente personas menores de 40 años.

Esta segmentación impedía que adultos mayores accedieran a oportunidades y vulneraba leyes antidiscriminatorias como la Age Discrimination in Employment Act (ADEA).

Empresas como Verizon y Amazon enfrentaron escrutinio legal por usar esta función. Posteriormente, Facebook modificó sus políticas de anuncios y resolvió varias demandas, comprometiéndose a prevenir discriminación por edad; aun así, el caso evidenció preocupaciones persistentes sobre transparencia y equidad en publicidad algorítmica.

12 Ejemplo 12: Sesgo algorítmico por edad en cobertura de salud post-aguda

SALUD | ADULTOS MAYORES | COBERTURA

Un caso notable de sesgo de IA relacionado con la edad involucró a NaviHealth, subsidiaria de UnitedHealth, que utilizaba un algoritmo llamado nH Predict para determinar la duración de cuidados post-agudos.

Después de que Gene Lokken, de 91 años, se fracturara la pierna, el algoritmo recomendó terminar prematuramente la cobertura para su rehabilitación en un hogar de cuidado, obligando a su familia a cubrir más de 12.000 dólares mensuales. Críticos argumentaron que la IA pasaba por alto las necesidades médicas complejas de pacientes mayores y afectaba de forma desproporcionada a las personas de edad avanzada.

Agencias regulatorias, incluida CMS, enfatizaron que las decisiones de atención deben basarse en evaluaciones individuales y no depender solamente de algoritmos.

El caso resalta la necesidad de transparencia, diseño equitativo y supervisión humana para evitar sesgos contra adultos mayores en decisiones sanitarias.

13 Ejemplo 13: Racismo y sesgo de género en sistemas comerciales de reconocimiento facial

RECONOCIMIENTO FACIAL | RAZA | GÉNERO

El proyecto Gender Shades de Joy Buolamwini reveló sesgos de IA en la precisión de sistemas comerciales de reconocimiento facial desarrollados por compañías como IBM, Microsoft y Face. El estudio encontró que, mientras las tasas de error para hombres de piel clara eran tan bajas como 0,8%, aumentaban hasta 34,7% para mujeres de piel oscura.

En conjunto, los sistemas clasificaban erróneamente el género en 1% de hombres blancos, pero hasta en 35% de mujeres negras, exponiendo un fuerte sesgo en los conjuntos de datos usados para entrenar estos modelos.

El trabajo de Buolamwini no solo subrayó los riesgos éticos de desplegar IA sin datos representativos; también presionó a grandes empresas tecnológicas a reevaluar y mejorar sus tecnologías de reconocimiento facial.

14 Ejemplo 14: Reclutamiento sesgado por IA en Amazon

EMPLEO | DATOS HISTÓRICOS | GÉNERO

Amazon tuvo que descartar una herramienta de reclutamiento sesgada por IA después de descubrir que degradaba hojas de vida que incluían la palabra "mujeres", como en "club de ajedrez de mujeres". También penalizaba a graduadas de universidades exclusivamente femeninas.

La herramienta funcionaba peor para candidatas mujeres porque había sido entrenada con datos históricos de contratación que favorecían a hombres.

15

Ejemplo 15: Disparidades raciales en predicción de riesgo sanitario basada en IA

SALUD | RIESGO | ACCESO HISTORICO

Un estudio publicado en Science reveló que el sesgo redujo en más de 50% el número de pacientes negros identificados para recibir atención adicional.

Los investigadores encontraron que un algoritmo ampliamente usado en hospitales de Estados Unidos, que afectaba a más de 200 millones de pacientes, favorecía significativamente a pacientes blancos sobre pacientes negros al predecir quienes necesitaban atención médica extra.

El algoritmo usaba el gasto en salud como sustituto de la necesidad. Como los pacientes negros históricamente habían tenido menor acceso a la atención y, por tanto, menor gasto, el sistema los marcaba erróneamente como de menor riesgo. Esto llevó a que recibieran menos apoyo, pese a tener necesidades de salud iguales o mayores.

16

Ejemplo 16: Sesgo racial en el editor de imágenes de Twitter

IMAGEN | RECORTE AUTOMÁTICO | RAZA

Se encontró que el algoritmo de recorte de imágenes de Twitter favorecía rostros blancos sobre rostros negros al generar vistas previas automáticamente. En 2020, usuarios comenzaron a experimentar con fotos lado a lado de personas de diferentes razas, como Barack Obama y Mitch McConnell, y observaron consistentemente que el algoritmo seleccionaba el rostro blanco para la miniatura, incluso cuando el rostro negro era más prominente.

Los experimentos se volvieron virales y provocaron críticas y preocupaciones amplias sobre sesgo de IA en los modelos de aprendizaje automático de Twitter.

Twitter finalmente reconoció el problema, señalando que el algoritmo había sido entrenado para priorizar rasgos "salientes" de la imagen, pero esas decisiones de entrenamiento produjeron resultados sesgados no intencionales. En respuesta, la empresa retiró la herramienta de recorte automático y adoptó vistas previas de imagen completa para evitar reforzar discriminación visual.

Autor del artículo original: Medha Mehta